

Visão Computacional

Aula 12

Segmentação de Imagens



Objetivos

- Introduzir os conceitos básicos de segmentação de imagens
 - Limiarização
 - Regiões
 - *Clustering*
 - Movimento

Segmentação



- Subdivide a imagem em partes ou objetos constituintes.
- O nível até o qual essa subdivisão deve ser realizada depende do problema sendo resolvido.
- A segmentação é uma das tarefas mais difíceis em visão computacional. Se ela falha, a maioria dos processos subsequentes estará comprometido.

Segmentação

- Os algoritmos de segmentação para imagens monocromáticas são geralmente baseados em uma das propriedades básicas:
 - Descontinuidade e similaridade

Limiarização

- Consiste em separar regiões de uma imagem quando esta apresenta duas classes:
 - Fundo e objeto (background, foreground)



Limiarização


- A maneira óbvia de extrair objetos é selecionar um limiar T que separe os dois grupos.
- Então, para cada ponto (x,y) tal que $f(x,y) > T$ é denominado ponto do objeto, caso contrario, fundo

$$g(x, y) = \begin{cases} 1 & \text{se } f(x, y) > T \\ 0 & \text{se } f(x, y) \leq T \end{cases}$$

- Nesse caso, T depende apenas de $f(x,y)$ e portanto é conhecida como limiarização global.

Limiarização Adaptativa

- Resultados satisfatórios são obtidos com a limiarização global.
- Porém em alguns casos, mais de um limiar deve ser utilizado.





Limiarização Adaptativa

- A limiarização adaptativa seleciona um limiar individual para cada pixel baseado no alcance da intensidade estimado em sua vizinhança local.
- Isso permite uma melhor limiarização quando não existem cumes bem definidos.

Limiarização Adaptativa

- Mecanismo para limiarização adaptativa
 - A imagem original é dividida em sub-imagens
 - Um limiar é determinado independentemente para cada região
 - Cada imagem R_i é então processada usando um limiar local
 - Uma nova imagem $R' = \cup R_i$

Segmentação por Regiões

- Seja R a região completa de uma imagem. Pode se imaginar a segmentação como um processo de dividir R em n regiões R_1, R_2, \dots, R_n , tal que:

$$\bigcup_{i=1}^n R_i = R$$

$$R_i \cap R_j = \emptyset$$

$$P(R_i) = V$$

$$P(R_i \cup R_j) = F$$

- Em que $P(R_i)$ é um predicado lógico (ex: todos os pixels possuem a mesma intensidade) sobre os pontos do conjunto R_i e \emptyset é o conjunto vazio.

Segmentação por Regiões

- Agregação de pixels
 - Agrupa pixels ou sub-regiões em regiões maiores.
 - Começa com um conjunto de pontos, chamados sementes, e a partir deles, cresce as regiões anexando a cada ponto semente aqueles pixels que possuam propriedades similares
 - Nível de cinza, textura, cor.

Segmentação por Regiões

Sementes →

0	0	5	6	7
1	1	5	8	7
0	1	6	7	7
2	0	7	6	6
0	1	5	6	5

$T=3$

0	0	5	6	7
1	1	5	8	7
0	1	6	7	7
2	0	7	6	6
0	1	5	6	5

Note que qualquer semente levaria ao mesmo resultado.

Propriedade P: Diferença absoluta entre os níveis de cinza daqueles entre o pixel e semente deve ser menor que T

Desvantagens:

- Seleção das sementes
- Seleção da propriedade P

Segmentação por Regiões

- Divisão e fusão
 - Seja R a imagem completa e seja P um predicado.
 - No caso de uma imagem quadrada, uma abordagem para segmentação de R consiste em subdividi-la sucessivamente em quadrantes cada vez menores de modo que $P(R_i) = V$.
 - Ou seja, se $P(R)$ for falso para qualquer quadrante, o quadrado deve ser subdividido em sub-quadrantes.
 - Essa técnica possui uma representação conveniente chamada *quadtree*



Segmentação por Regiões

- As fusões são limitadas inicialmente a grupos de quatro blocos que sejam descendentes na representação *quadtree* e que satisfaçam o predicado P.
- Quando fusões desse tipo não forem mais possíveis, o procedimento é terminado por uma fusão final.

a b

FIGURE 10.42

(a) Partitioned image.
(b) Corresponding quadtree.



Clustering

- Existem basicamente dois tipos de clustering:
 - **Divisive**
 - A imagem é vista como um cluster, e então são feitas divisões sucessivas.
 - Segmentação por regiões.
 - **Agglomerative**
 - Cada pixel é visto como um cluster, e clusters são unidos recursivamente até formarem um bom cluster.



Clustering

- Parâmetro a definir
 - Número de clusters.
 - Geralmente não se conhece a priori o número de clusters que existem na imagem.

Clustering

- Uma coleção de objetos que são similares entre si, e diferentes dos objetos pertencentes a outros clusters.
- Isso requer uma medida de similaridade.
- No exemplo anterior, a similaridade utilizada foi a *distância*.
 - *Distance-based Clustering*


k-Means Clustering

- É a técnica mais simples de aprendizagem não supervisionada.
- Consiste em fixar k centróides (de maneira aleatória), um para cada grupo (clusters).
- Associar cada indivíduo ao seu centróide mais próximo.
- Recalcular os centróides com base nos indivíduos classificados.

Algoritmo *k-Means*


1. Determinar os centróides
2. Atribuir a cada objeto do grupo o centróide mais próximo.
3. Após atribuir um centróide a cada objeto, recalcular os centróides.
4. Repetir os passos 2 e 3 até que os centróides não sejam modificados.

k-Means - Um Exemplo




Objetos em um plano 2D

k-Means - Um Exemplo




Passo 1: Centróides inseridos aleatoriamente

k-Means - Um Exemplo




Passo 2: Atribuir a cada objeto o centróide mais próximo

k-Means - Um Exemplo



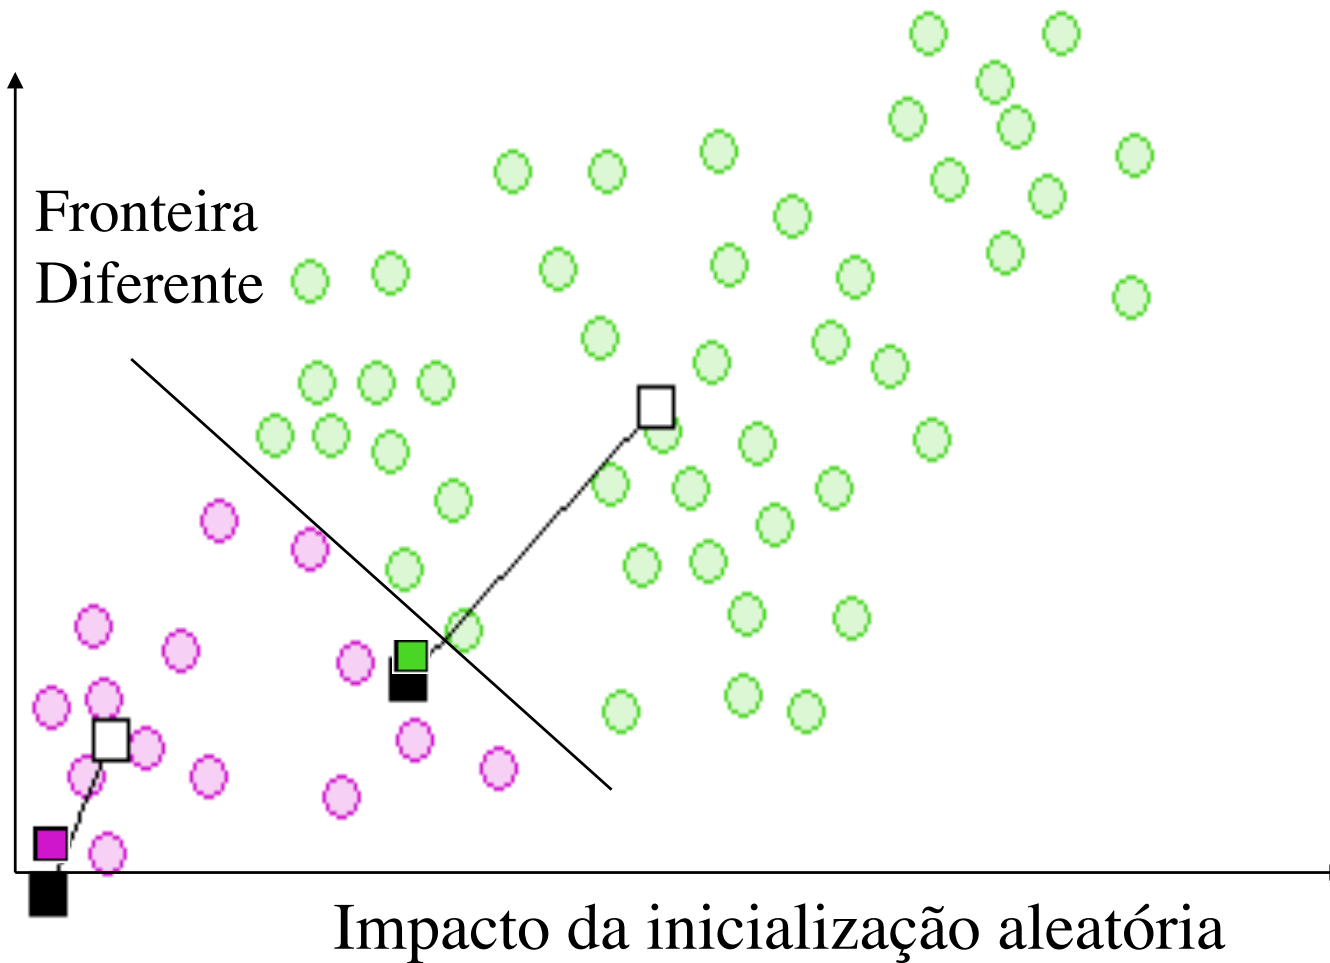
Passo 3: Recalcular os centróides

k-Means - Um Exemplo



Impacto da inicialização aleatória.

k-Means - Um Exemplo






k-Means - Inicialização

- Importância da inicialização.
- Quando se têm noção dos centróides, pode-se melhorar a convergência do algoritmo.
- Execução do algoritmo várias vezes, permite reduzir impacto da inicialização aleatória.

k-Means - Um Exemplo



4 Centróides

Movimento

- O movimento é uma poderosa pista usada pelos seres humanos e animais para a extração de um objeto de interesse de um fundo de detalhes irrelevantes.
- Abordagem básica
 - A abordagem mais simples para a detecção de mudanças entre dois quadros de imagem $f(x,y,t_i)$ e $f(x,y,t_j)$ tomados em instantes t_i e t_j , respectivamente, é através da comparação de imagens pixel a pixel.

Movimento

$$d_{ij}(x, y) = \begin{cases} 1 & \text{se } |f(x, y, t_i) - f(x, y, t_j)| > \Theta \\ 0 & \text{caso contrario} \end{cases}$$

- Essa abordagem pode ser aplicada quando a iluminação é relativamente constante.
- Além de objetos em movimento, a imagem da diferença pode contar com pequenos ruídos e objetos que se movem vagarosamente.

Movimento

- Subtração do fundo
 - Fazer a média (mediana) de várias imagens afim de criar uma aproximação do fundo.
 - Subtrair os quadros subsequentes desta aproximação.
 - Objetos que não fazem parte do fundo da cena apareceram como resultado desta operação de segmentação.





Próxima aula...

- Segmentação de imagens
 - Transformada Hough