

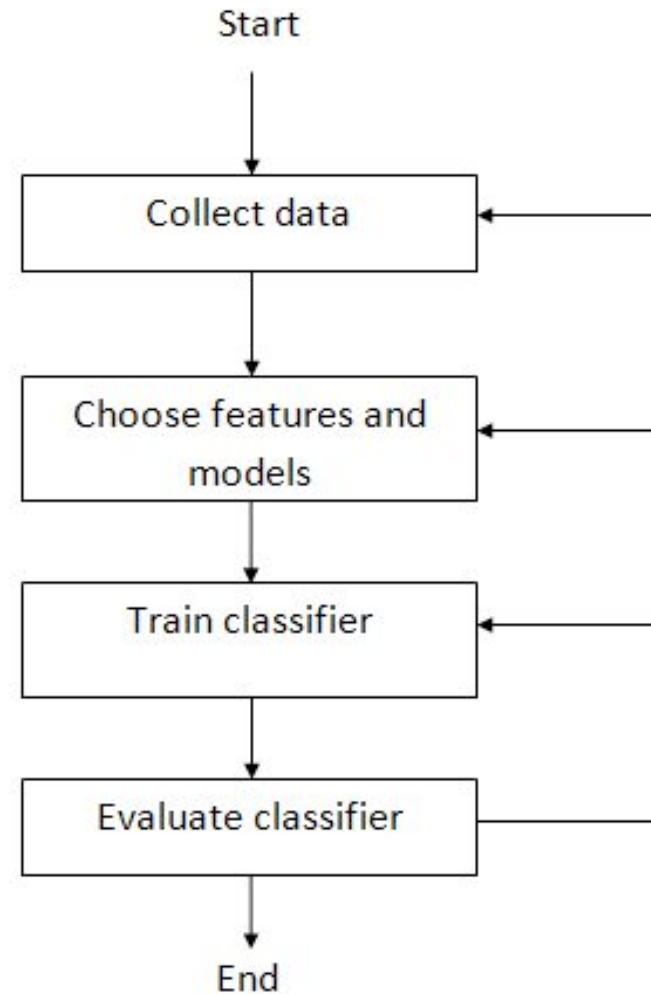
Visão Computacional

Aula 14

Reconhecimento de Padrões

Elementos Básicos

- Modelo Genérico



Introdução

- Em VC - Modelo Simples



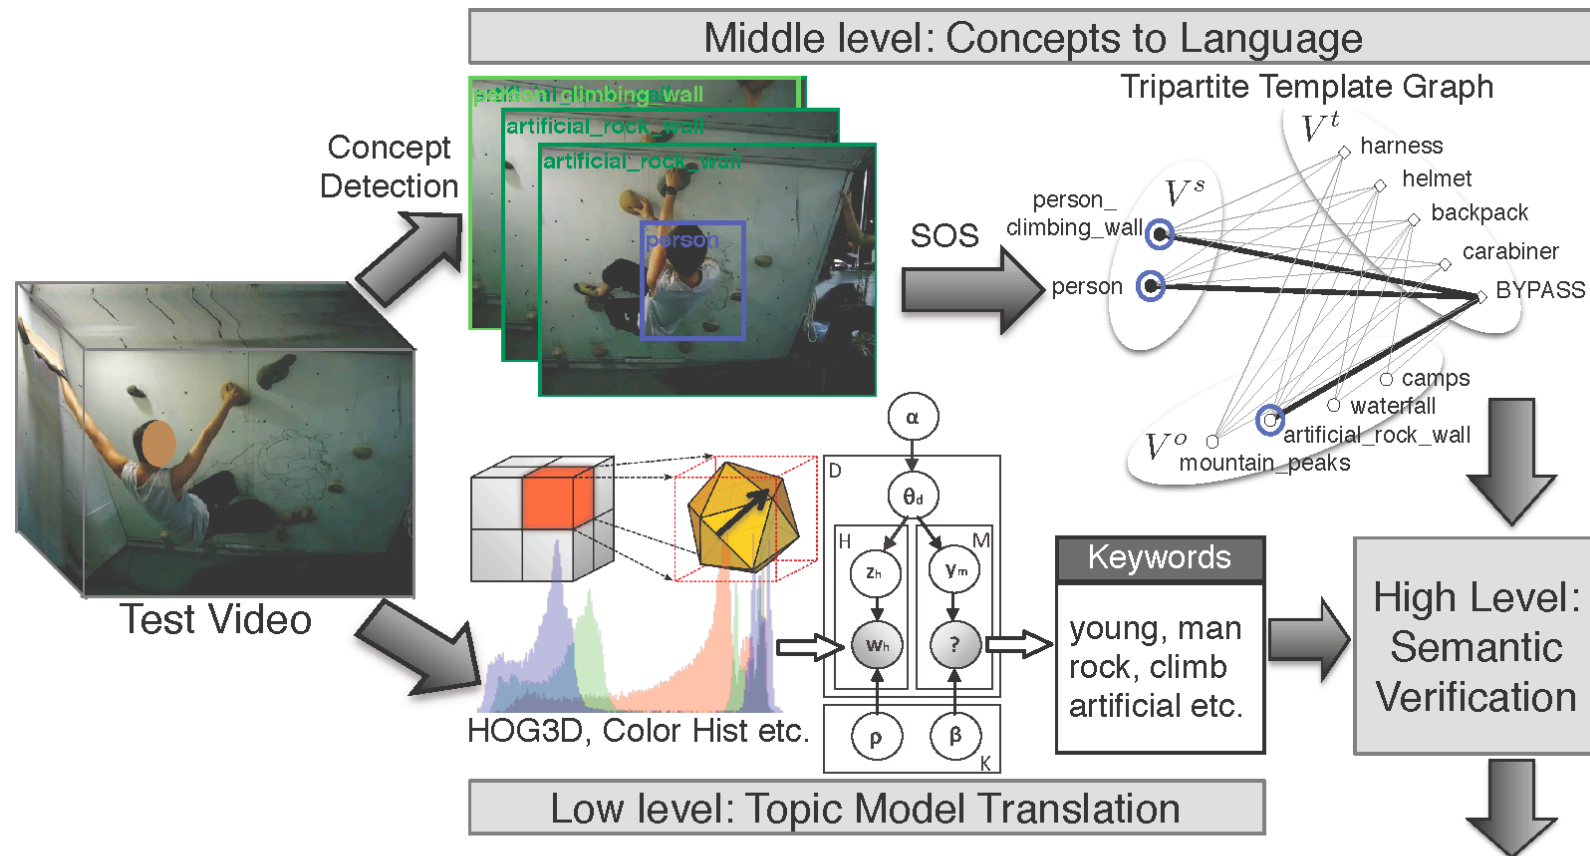
Introdução

- Em VC - Modelo Simples



Elementos Básicos

- Modelo Complexo



Output from our system: 1) A person is on artificial rock wall. 2) A person climbing a wall is on artificial rock wall. 3) Person climbs rock wall indoors. 4) Young man tries to climb artificial rock wall. 5) A man demonstrates how to climb a rock wall.

Definindo os “Padrões”

- Padrão
 - Descrição quantitativa de um objeto ou alguma outra entidade de interesse na imagem
 - Em geral, um padrão é formado por um ou mais descritores(Características)

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$




Características de uma imagem

- Globais: histograma, conteúdo de frequências, etc...
- Locais: regiões com determinada propriedade, arestas, cantos, curvas, etc...

Exemplo: Arestas e cantos


- Locais de mudanças significativas na intensidade da imagem



Exemplo - flores Iris


FIGURE 12.1

Three types of iris flowers described by two measurements.



Exemplo padrão descrito pela assinatura

- Geração de um vetor de características através da assinatura



a b

FIGURE 12.2 A noisy object and its corresponding signature.

Descrição por árvores





FIGURE 12.5 A tree description of the image in Fig. 12.4.

Métodos de decisão teórica

- Dado:
 - $x=(x_1,x_2,\dots,x_n)^T$, um vetor de n dimensões
 - M classes: $\omega_1, \omega_2, \dots, \omega_m$
- Deseja-se encontrar M funções de decisão (discriminantes) $d_1(x), d_2(x), \dots, d_M(x)$, com a propriedade
 - $d_i(x) > d_j(x), j=1,2,\dots,M; j \neq i$
- Se o padrão x pertencer a classe ω_i

Classificador de distância mínima

- Suponha que cada classe de padrões seja representada por um vetor protótipo (ou médio)

$$m_j = \frac{1}{N_j} \sum_{x \in \omega_j} x, \quad j = 1, 2, \dots, M$$

- N_j é o número de vetores da classe ω_j
- Uma maneira de definir a classe de um padrão desconhecido x é atribuí-lo à classe de cujo protótipo encontra-se mais próximo.

Classificador de distância mínima

- A distância euclidiana pode ser usada para determinar proximidade

$$D_j(x) = \|x - m_j\|, j = 1, 2, \dots, M$$

Dado que $\|a\| = (a^T a)^{1/2}$ é a norma euclidiana

- Atribui-se x à classe ω_j se $D_i(x)$ for a menor distância.

Classificador de distância mínima

- É possível mostrar que a equação anterior equivale a:

$$d_j(x) = x^T m_j - \frac{1}{2} m_j^T m_j, \quad j = 1, 2, \dots, M$$

- Ou seja, atribuir x à classe ω_j se $d_i(x)$ tiver o maior valor numérico.

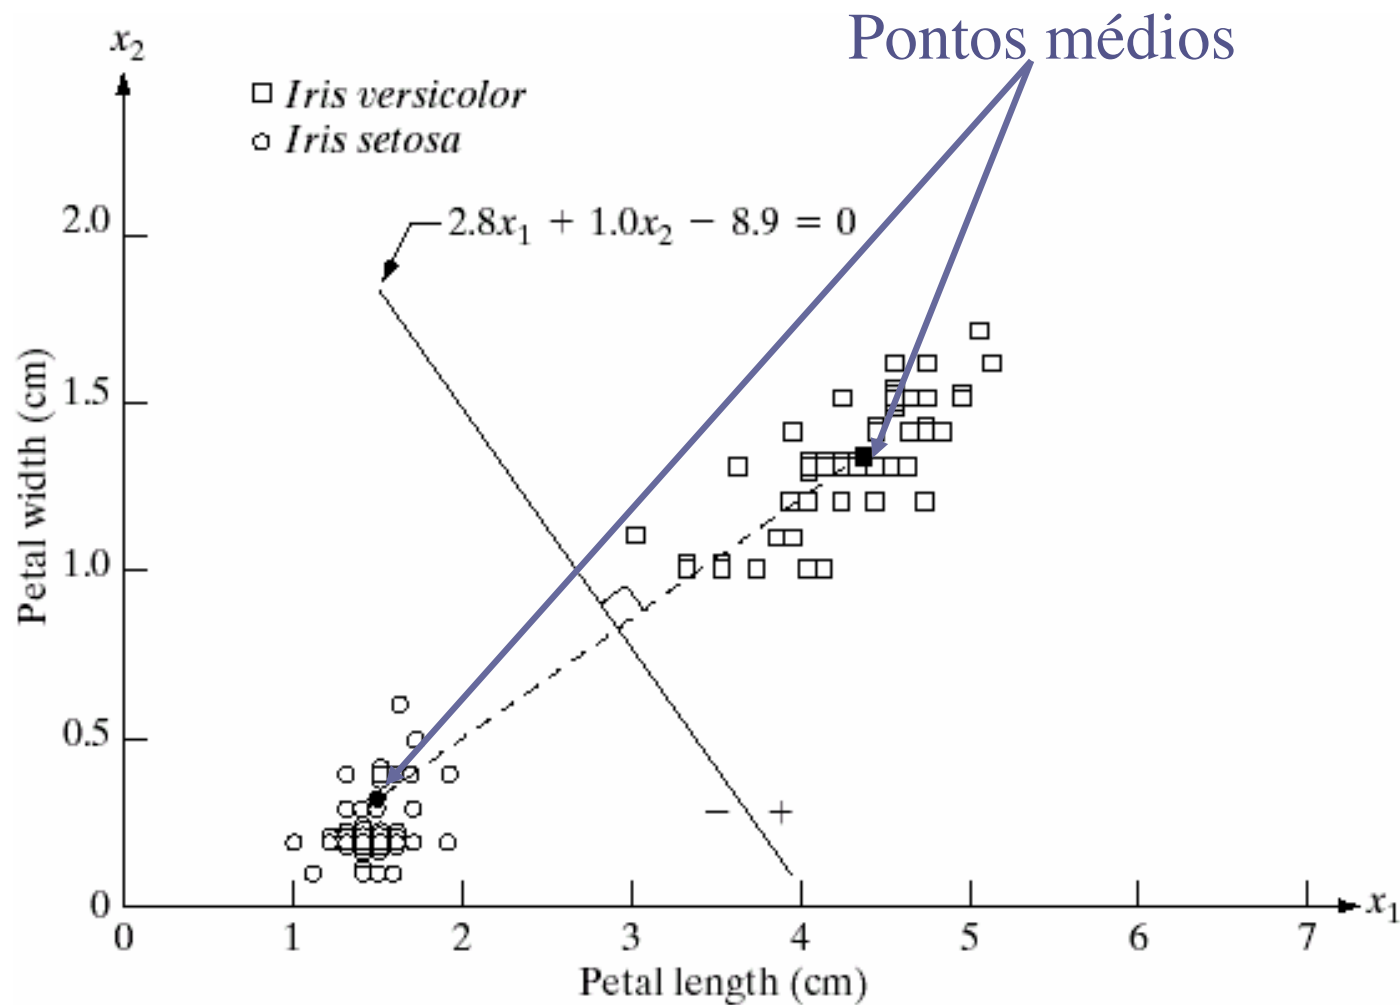
Classificador de distância mínima

- A fronteira de decisão entre as classes ω_i e ω_j para o classificador de distância mínima é:

$$\begin{aligned}d_{ij}(x) &= d_i(x) - d_j(x) \\ &= x^T(m_i - m_j) - \frac{1}{2}(m_i - m_j)^T(m_i - m_j) = 0\end{aligned}$$

- A superfície dada pela equação é a bissetção perpendicular do segmento de linha entre m_i e m_j .
- Para $n=2$ é uma linha, para $n=3$ é um plano e para $n>3$ é chamada de hiperplano

Classificador de distância mínima



Classificador de distância mínima

- O classificador de distância mínima funciona bem quando a distância entre as médias é grande quando comparada com a dispersão de cada classe em relação a sua média.
- Na prática, problemas com essas características são raros, a menos que a entrada dos dados seja bem controlada.

Casamento por correlação - Window Matching

- Objetivo:
 - Encontrar casamentos de uma subimagem $w(x,y)$ de tamanho $J \times K$ dentro de uma imagem $f(x,y)$ de tamanho $M \times N$, assumindo que $J \leq M$ e $K \leq N$.
 - Em sua forma mais intuitiva

$$c(s, t) = \sum_x \sum_y f(x, y) w(x - s, y - t)$$

Casamento por correlação




FIGURE 12.8 Arrangement for obtaining the correlation of f and w at point (x_0, y_0) .

Casamento por correlação

- A função de correlação dada pela equação anterior possui a desvantagem de ser sensível a mudança na amplitude de $f(x,y)$ e de $w(x,y)$.

Casamento por correlação


- Assim é comum utilizar o coeficiente de correlação para realizar o casamento

$$\gamma(s, t) = \frac{\sum_x \sum_y [f(x, y) - \bar{f}(x, y)][w(x - s, y - t) - \bar{w}]}{\left\{ \sum_x \sum_y [f(x, y) - \bar{f}(x, y)]^2 [w(x - s, y - t) - \bar{w}]^2 \right\}^{\frac{1}{2}}}$$



\bar{w} – é o valor médio dos pixels em $w(x, y)$

$\bar{f}(x, y)$ – é o valor médio na região sob análise de $f(x, y)$

Casamento por correlação (exemplo)



Casamento por correlação (exemplo)



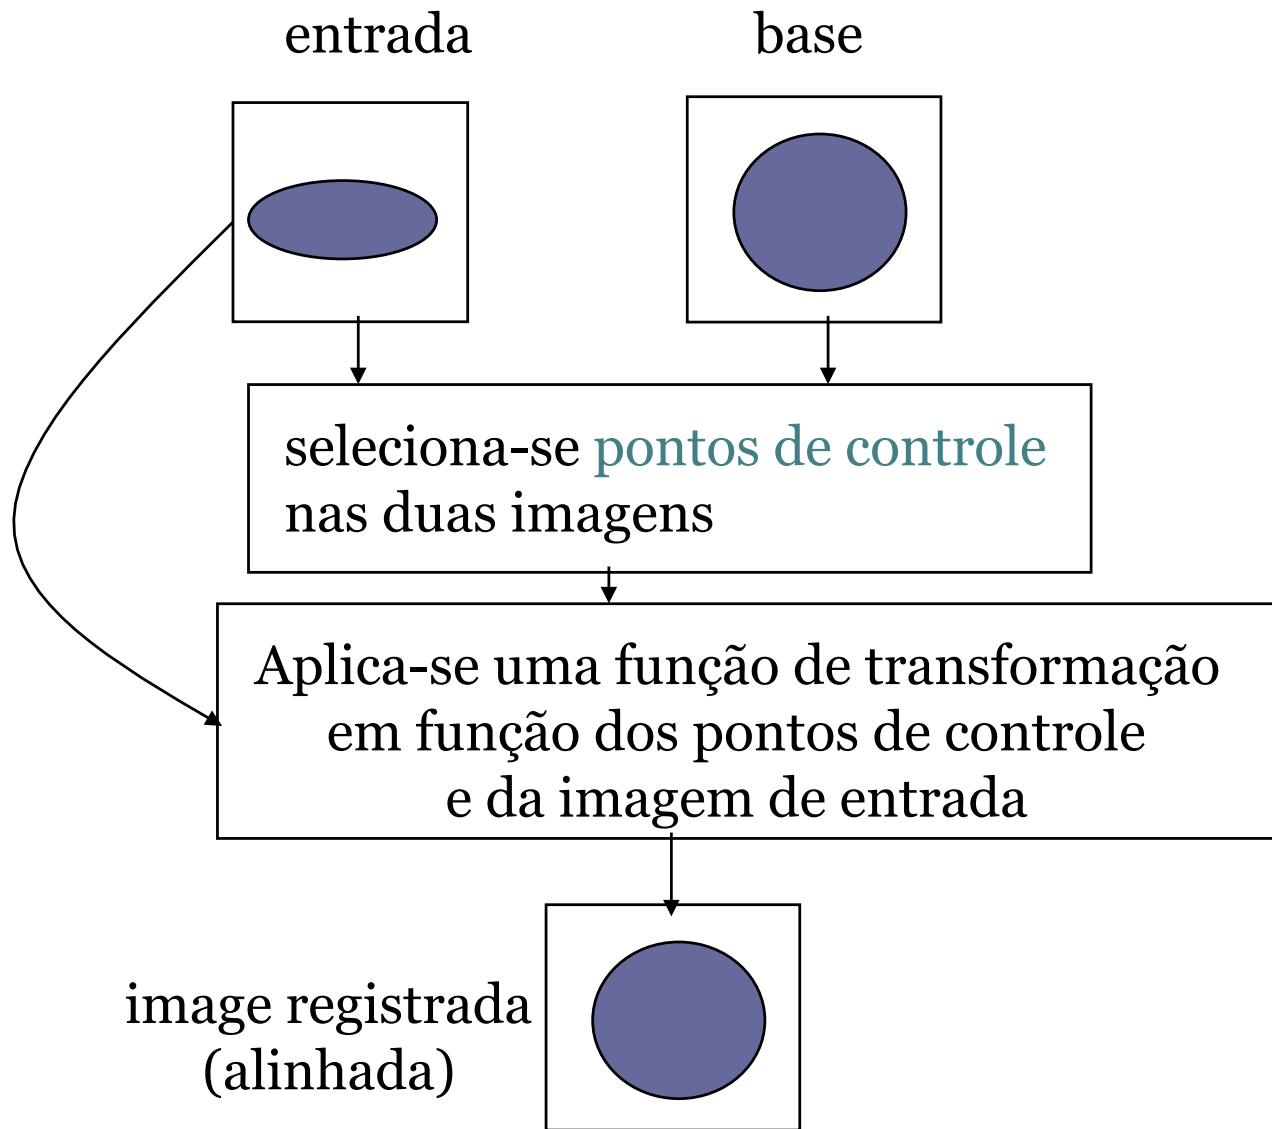
Aplicação

- Alinhamento de Imagens
 - Image Registration
- Aplicação que envolve reconhecimento de padrões
 - Transformação de Coordenadas + Correlação de Pontos




Registro de Imagens

- Alinhamento de duas ou mais imagens da mesma cena
- Considera duas imagens: imagem de base ou referência e imagem de entrada
- O objetivo é alinhar a imagem de entrada com a imagem de base através de transformações espaciais aplicadas à imagem de entrada



Pontos de Controle



$$x' = r(x, y)$$

$$y' = s(x, y)$$

Transformação Projetiva

A **transformação projetiva** mapeia quadriláteros para quadriláteros.

$$[w \ z \ h] = [x \ y \ 1] \begin{bmatrix} c_1 & c_4 & c_7 \\ c_2 & c_5 & c_8 \\ c_3 & c_6 & 1 \end{bmatrix}$$

e

$$x' = \frac{w}{h} \quad , \quad y' = \frac{z}{h}$$

ou

$$x' = \frac{c_1x + c_2y + c_3}{c_7x + c_8y + 1} \quad , \quad y' = \frac{c_4x + c_5y + c_6}{c_7x + c_8y + 1}$$

Exemplo 1:


Base



Entrada



Pontos de controle



Entrada (distorcida)



Registrada



Base



Registrada



Superposição (base + registrada)





Links

- Wiki Image Stitching
 - http://en.wikipedia.org/wiki/Photo_stitching
- CleVr
 - <http://www.clevr.com/stitcher>



Próxima aula...

- Reconhecimento de Padrões
 - Bag of Features